

UNIVERSITA' DI PISA

Dipartimento di Informatica

RETI NEURALI RICORRENTI

Un'analisi sperimentale comparativa per la predizione dello
stato fisico ed emotivo

Candidato:

Niccolò Puccinelli

Relatori:

Dr. Claudio Gallicchio

Prof. Davide Bacciu

Dr. Daniele Di Sarli

Controrelatore:

Prof. Federico Giovanni Poloni



Aspetti principali

- 5 dataset biometrici.
- 4 modelli di **RNN**.
- Task di **classificazione**.
- Sviluppo tecnologia più adatta per dispositivi indossabili.
- **Pre-processing** dei dati.
- **Model selection**.
- Confronto con risultati raggiunti in letteratura.

Reti Neurali

Feed-Forward

- Le connessioni tra le unità avanzano in un'unica direzione.
- **Assenza di memoria.**
- Input indipendenti.

Ricorrenti

- Presenza di cicli tra le unità: *backpropagation*.
- **Memoria di stato.**
- Input dipendenti tra loro.
- Suddivisione dei dati in **sottosequenze temporali**.


Problemi dovuti alla *backpropagation*:

- Scomparsa del gradiente.
- Esplosione del gradiente.

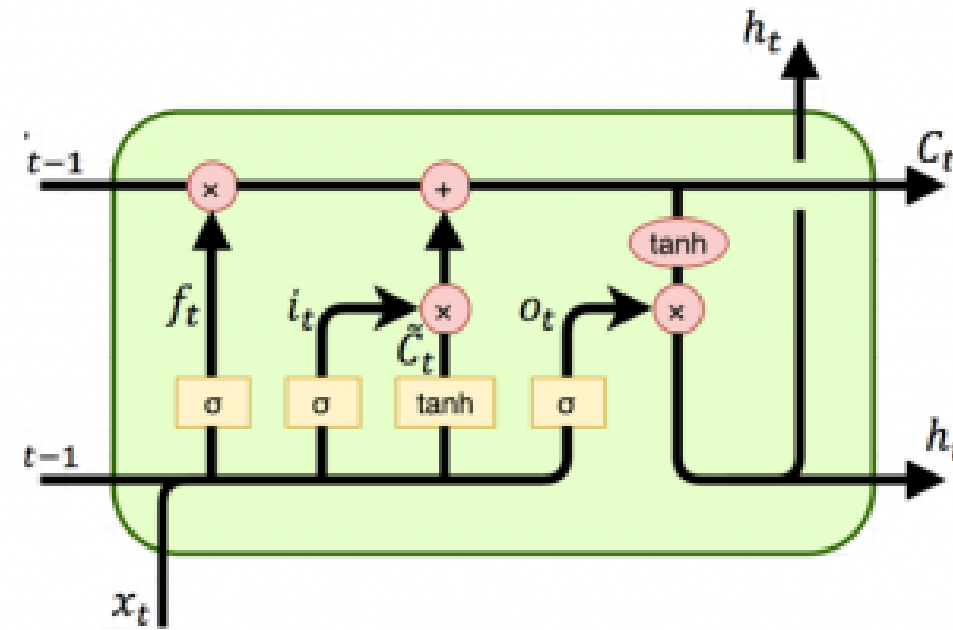
Soluzione:

- *Long Short-Term Memory* (**LSTM**).
- *Gated Recurrent Unit* (**GRU**).


RNN



LSTM



GRU



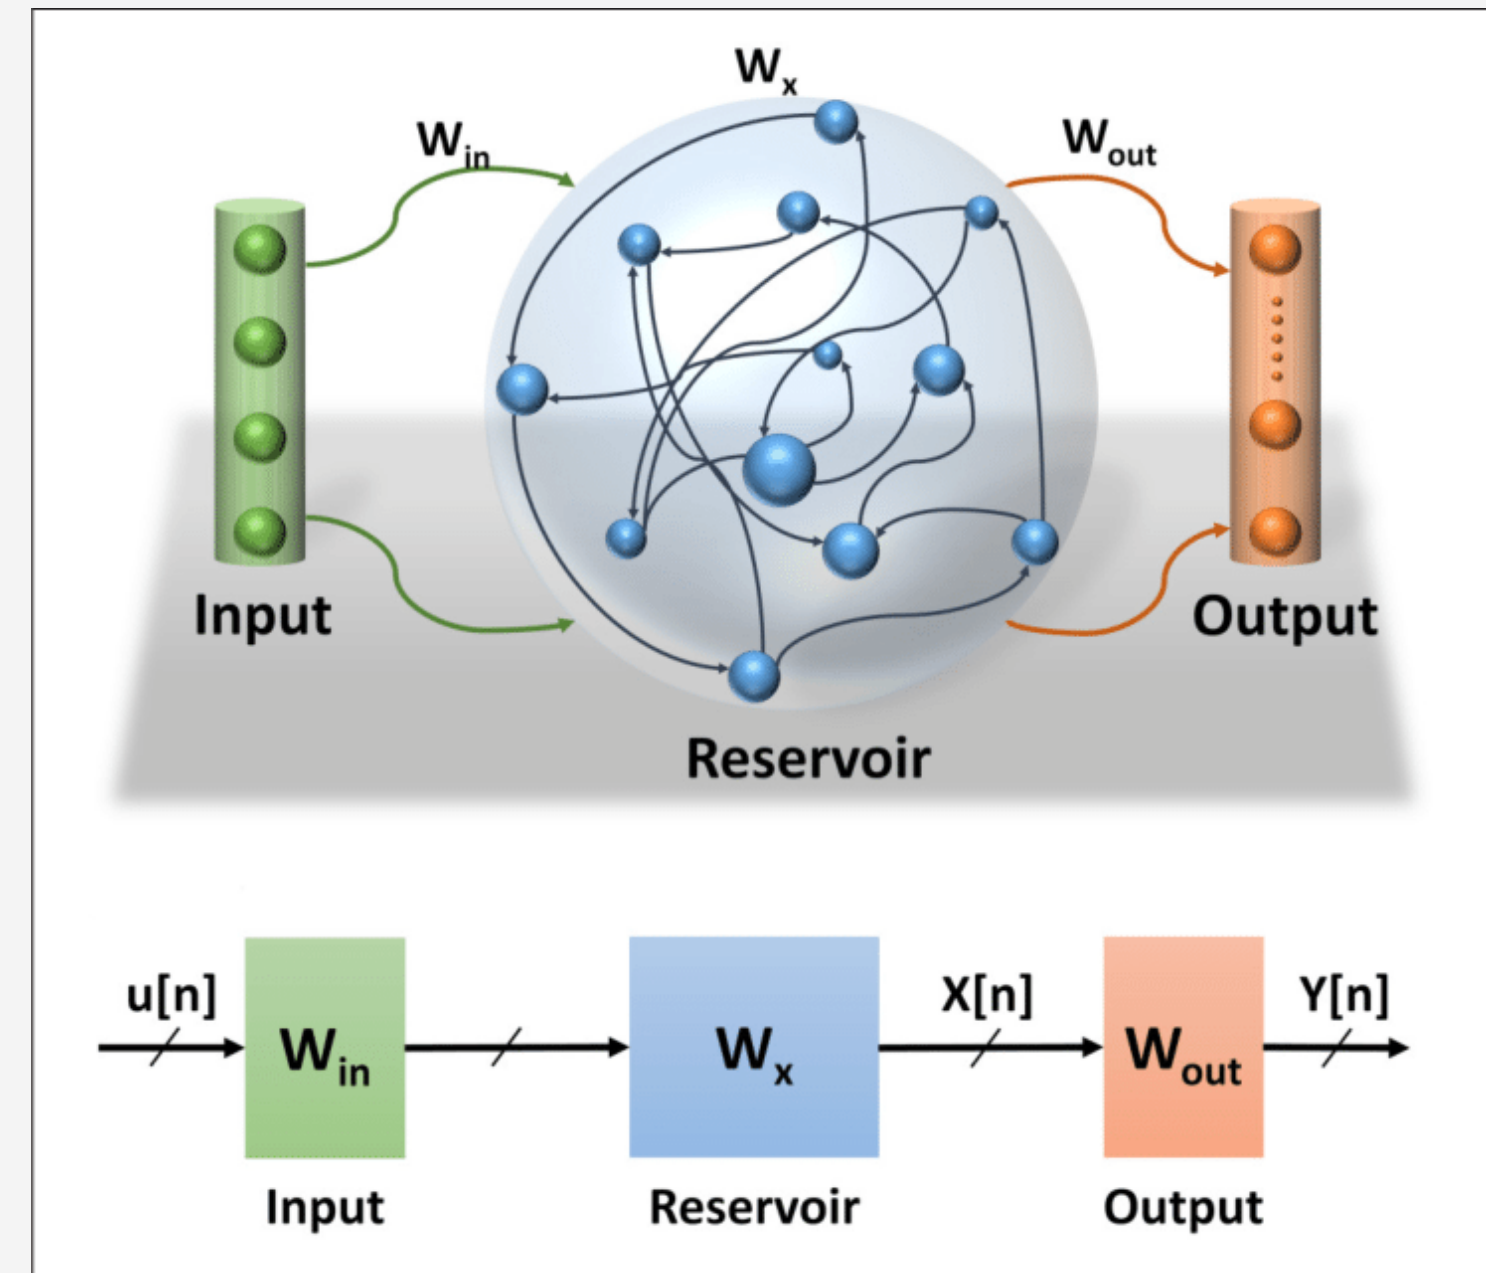
<http://dprogrammer.org/rnn-lstm-gru>

Tuttavia:

- Architetturealmente complessi.
- Maggiore complessità dell'algoritmo di addestramento.

Echo State Network

- Paradigma **Reservoir Computing** (RC): concettuale separazione tra la parte non lineare ricorrente (**reservoir**) e la parte *feed-forward* in uscita (**readout**).
- **Reservoir**: $\mathbf{X}(n) = \tanh(\mathbf{W}_{in}(\mathbf{u}(n)) + \mathbf{W}_x(\mathbf{x}(n-1)))$
- **Readout**: $\mathbf{Y}(n) = \mathbf{W}_{out} \mathbf{X}(n)$



Dhiresha Kudithipudi, Qutaiba Saleh, Cory Merkel James Thesing and Bryant Wysocki, "Design and Analysis of a Neuromemristive Reservoir Computing Architecture for Biosignal Processing", Frontier in Neuroscience, 2016.

Efficienza del modello ESN



Addestramento

L'addestramento coinvolge esclusivamente il *readout*.



Echo State Property

Dipendenze iniziali progressivamente perse.

Dataset utilizzati

► WESAD

WEarable Stress and Affect Detection

Soggetti: 15

Sensori:

- Pulsazioni del sangue
- Elettrocardiogramma
- Attività elettrodermica
- Elettromiogramma
- Respirazione
- Temperatura corporea
- Accelerometro

Attività:

- **0:** *baseline*
- **1:** *stress*
- **2:** *amusement*
- **3:** *meditation*

► HAR

Heterogeneity Activity Recognition

Soggetti: 9

Sensori:

- Accelerometro smartphone
- Accelerometro smartwatch
- Giroscopio smartphone
- Giroscopio smartwatch

Attività:

- **0:** *stand*
- **1:** *sit*
- **2:** *walk*
- **3:** *stairsup*
- **4:** *stairsdown*
- **5:** *bike*

► PAMAP2

*Physical Activity
Monitoring Data Set*

Soggetti: 9

Sensori:

- Pulsazioni del sangue
- Temperatura
- Accelerometro
- Giroscopio
- Magnetometro

Attività:

- **0:** *lying*
- **1:** *sitting*
- **2:** *standing*
- **3:** *walking*

► OPPORTUNITY

*Opportunity Activity
Recognition*

Soggetti: 4

Sensori:

- Accelerometro
- Giroscopio
- Magnetometro
- Orientamento dei sensori

Attività:

- **0:** *standing*
- **1:** *walking*
- **2:** *sitting*
- **3:** *lying*

► ASCERTAIN

*data base for implicit personality
and Affect recognition*

Soggetti: 58

Sensori:

- Elettrocardiogramma
- Elettroencefalogramma
- Attività elettrodermica

Attività:

- **0:** *arousal > 3 & valence > 0*
- **1:** *arousal > 3 & valence ≤ 0*
- **2:** *arousal ≤ 3 & valence > 0*
- **3:** *arousal ≤ 3 & valence ≤ 0*

Pre-processing dei dati



Rimozione dati inaccurati

Sono stati rimossi dati relativi a sensori e soggetti poco precisi.



Suddivisione dei dati

Sottosequenze temporali.

→ Impiego vantaggioso delle RNN.



Sampling Bias

Selezione di un numero di sottosequenze temporali il più equo possibile, per ciascuna attività.

Model selection

- Combinazioni casuali di numerosi **iperparametri**.
→ Viene scelta quella che garantisce meno *loss* sul validation-set.
- Addestramento sul training-set.
- Valutazione delle performance basata su *accuracy* sul test-set.
- Numero esplorato di parametri addestrabili uguale per ogni modello.
- Ricerca di un **compromesso** tra complessità dei modelli e affidabilità dei risultati.

Iperparametri testati:


ESN	Ottimizzazione (Adam)	Regolarizzazione (l1_l2)	Numero di unità e layer	Numero di epoche
<ul style="list-style-type: none">• input_scaling: [0.5, 2.0]• leaky: [0.3, 1.0]• spectral_radius: [0.5, 1.5]	<ul style="list-style-type: none">• learning_rate: [0.001, 0.01]• beta_1: [0.8, 0.99]• beta_2: [0.98, 0.999]	<ul style="list-style-type: none">• kernel_reg: [1e-6, 1e-4]• bias_reg: [1e-6, 1e-4]• activity_reg: [1e-6, 1e-4]	Ricerca in base a miglioramento della <i>loss</i> sul validation-set.	Tramite <i>callback</i> Early_stopping.

Caching ESN

- **RNN**: stati ricalcolati per ogni sequenza di input.
- **ESN**: stati calcolati solo all'inizio.
- Drastica **riduzione** del tempo di addestramento.

Addestramento

- Focus su dispositivi indossabili → **Hold-out** validation.



- **Cross-Validation:**

Pro

Prestazioni migliori e riduzione rischio di *overfitting*.


Contro

Significativo incremento del tempo di addestramento.

Risultati ottenuti




WESAD



- **DT** = Decision Tree [1].
- **RF** = Random Forest [1].
- **AB** = Ada-Boost Decision Tree [1].
- **LDA** = Linear Discriminant Analysis [1].
- **kNN** = k Nearest Neighbors [1].

*: Considerando task di classificazione con 3 classi invece di 4 e addestramento tramite 10-Folds-CV.

HAR



- **C4.5 DT** = C4.5 Decision Tree [2].
- **SVM** = Support Vector Machines [2].
- **kNN** = k Nearest Neighbors [2].
- **DNN** = Deep Neural Network (*feed-forward*) [3].

*: Addestramento tramite 10-Folds-CV.

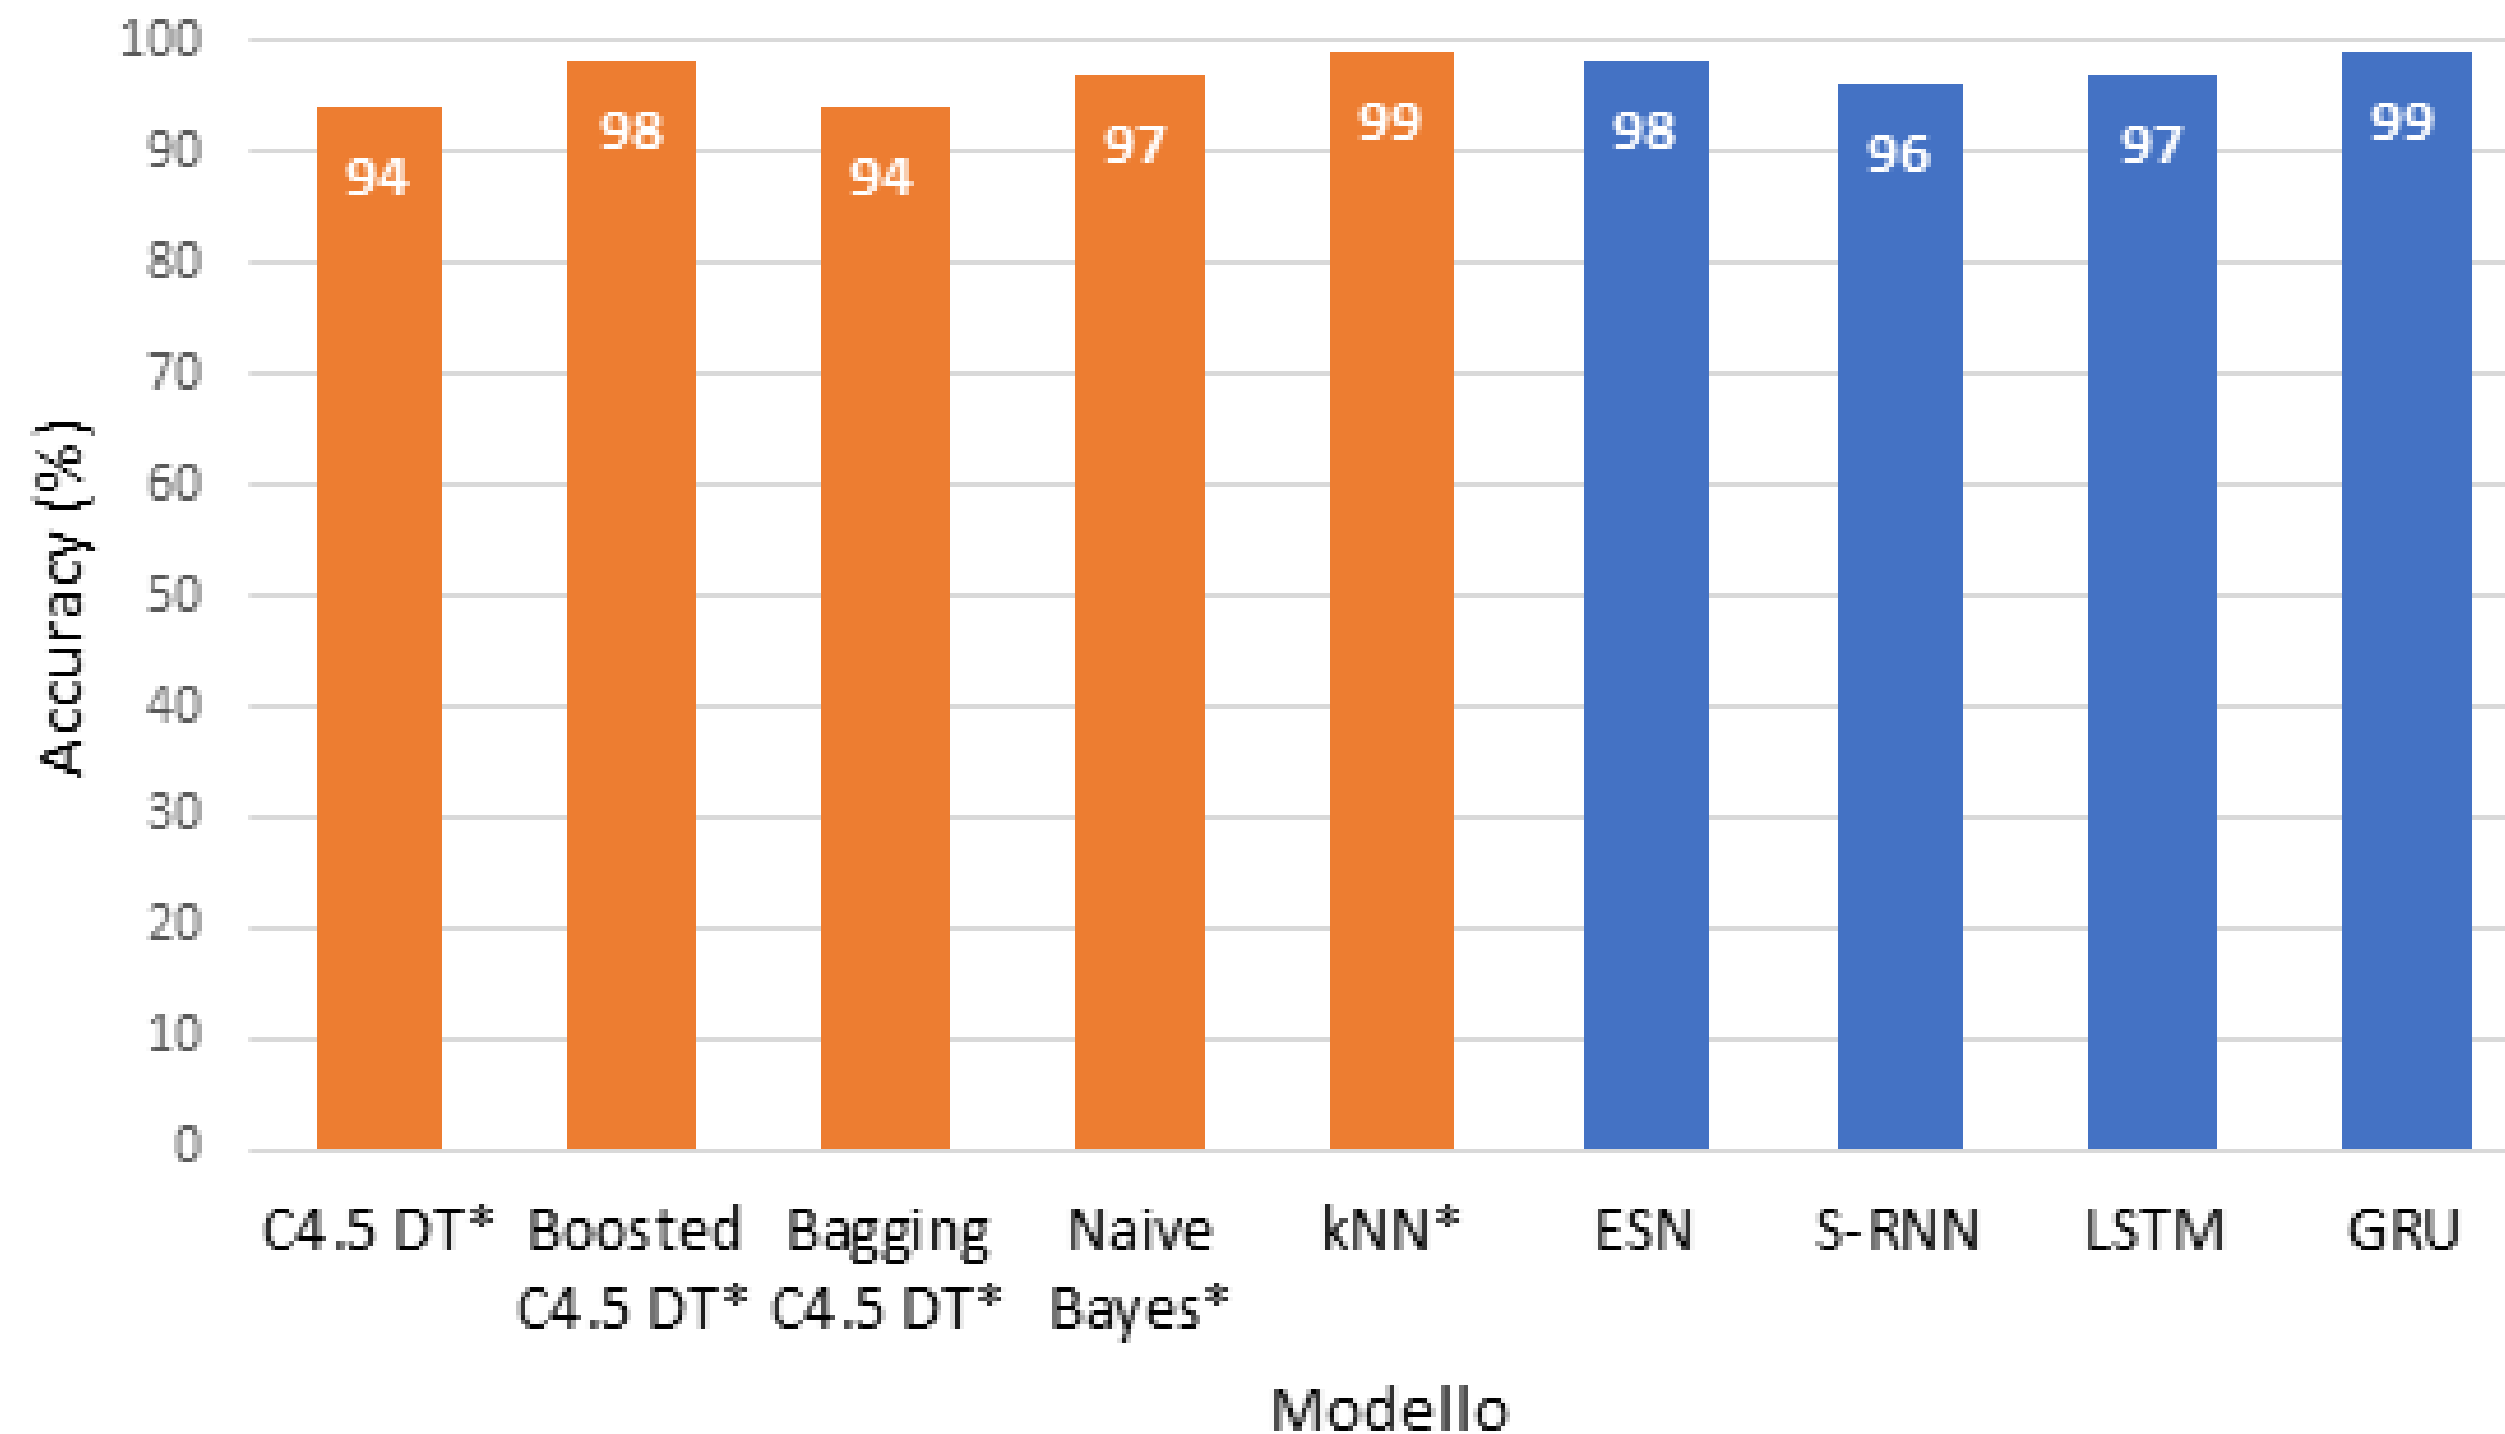
** : Considerando un numero di parametri addestrabili esplorati 4 volte maggiore.

[2]: Allan Stisen et al., "Smart Devices are Different: Assessing and Mitigating Mobile Sensing Heterogeneities for Activity Recognition", in: Proc. 13th ACM Conference on Embedded Networked Sensor Systems (SenSys 2015), Seoul, Korea, 2015..

[3]: Konstantin Sozinov, et al. "Human Activity Recognition Using Federated Learning", in: IEEE Int. Conf. on Parallel & Distributed Processing with Applications, Ubiquitous Computing & Communications, Big Data & Cloud Computing,, 2019, pp. 1103–1111.



PAMAP2



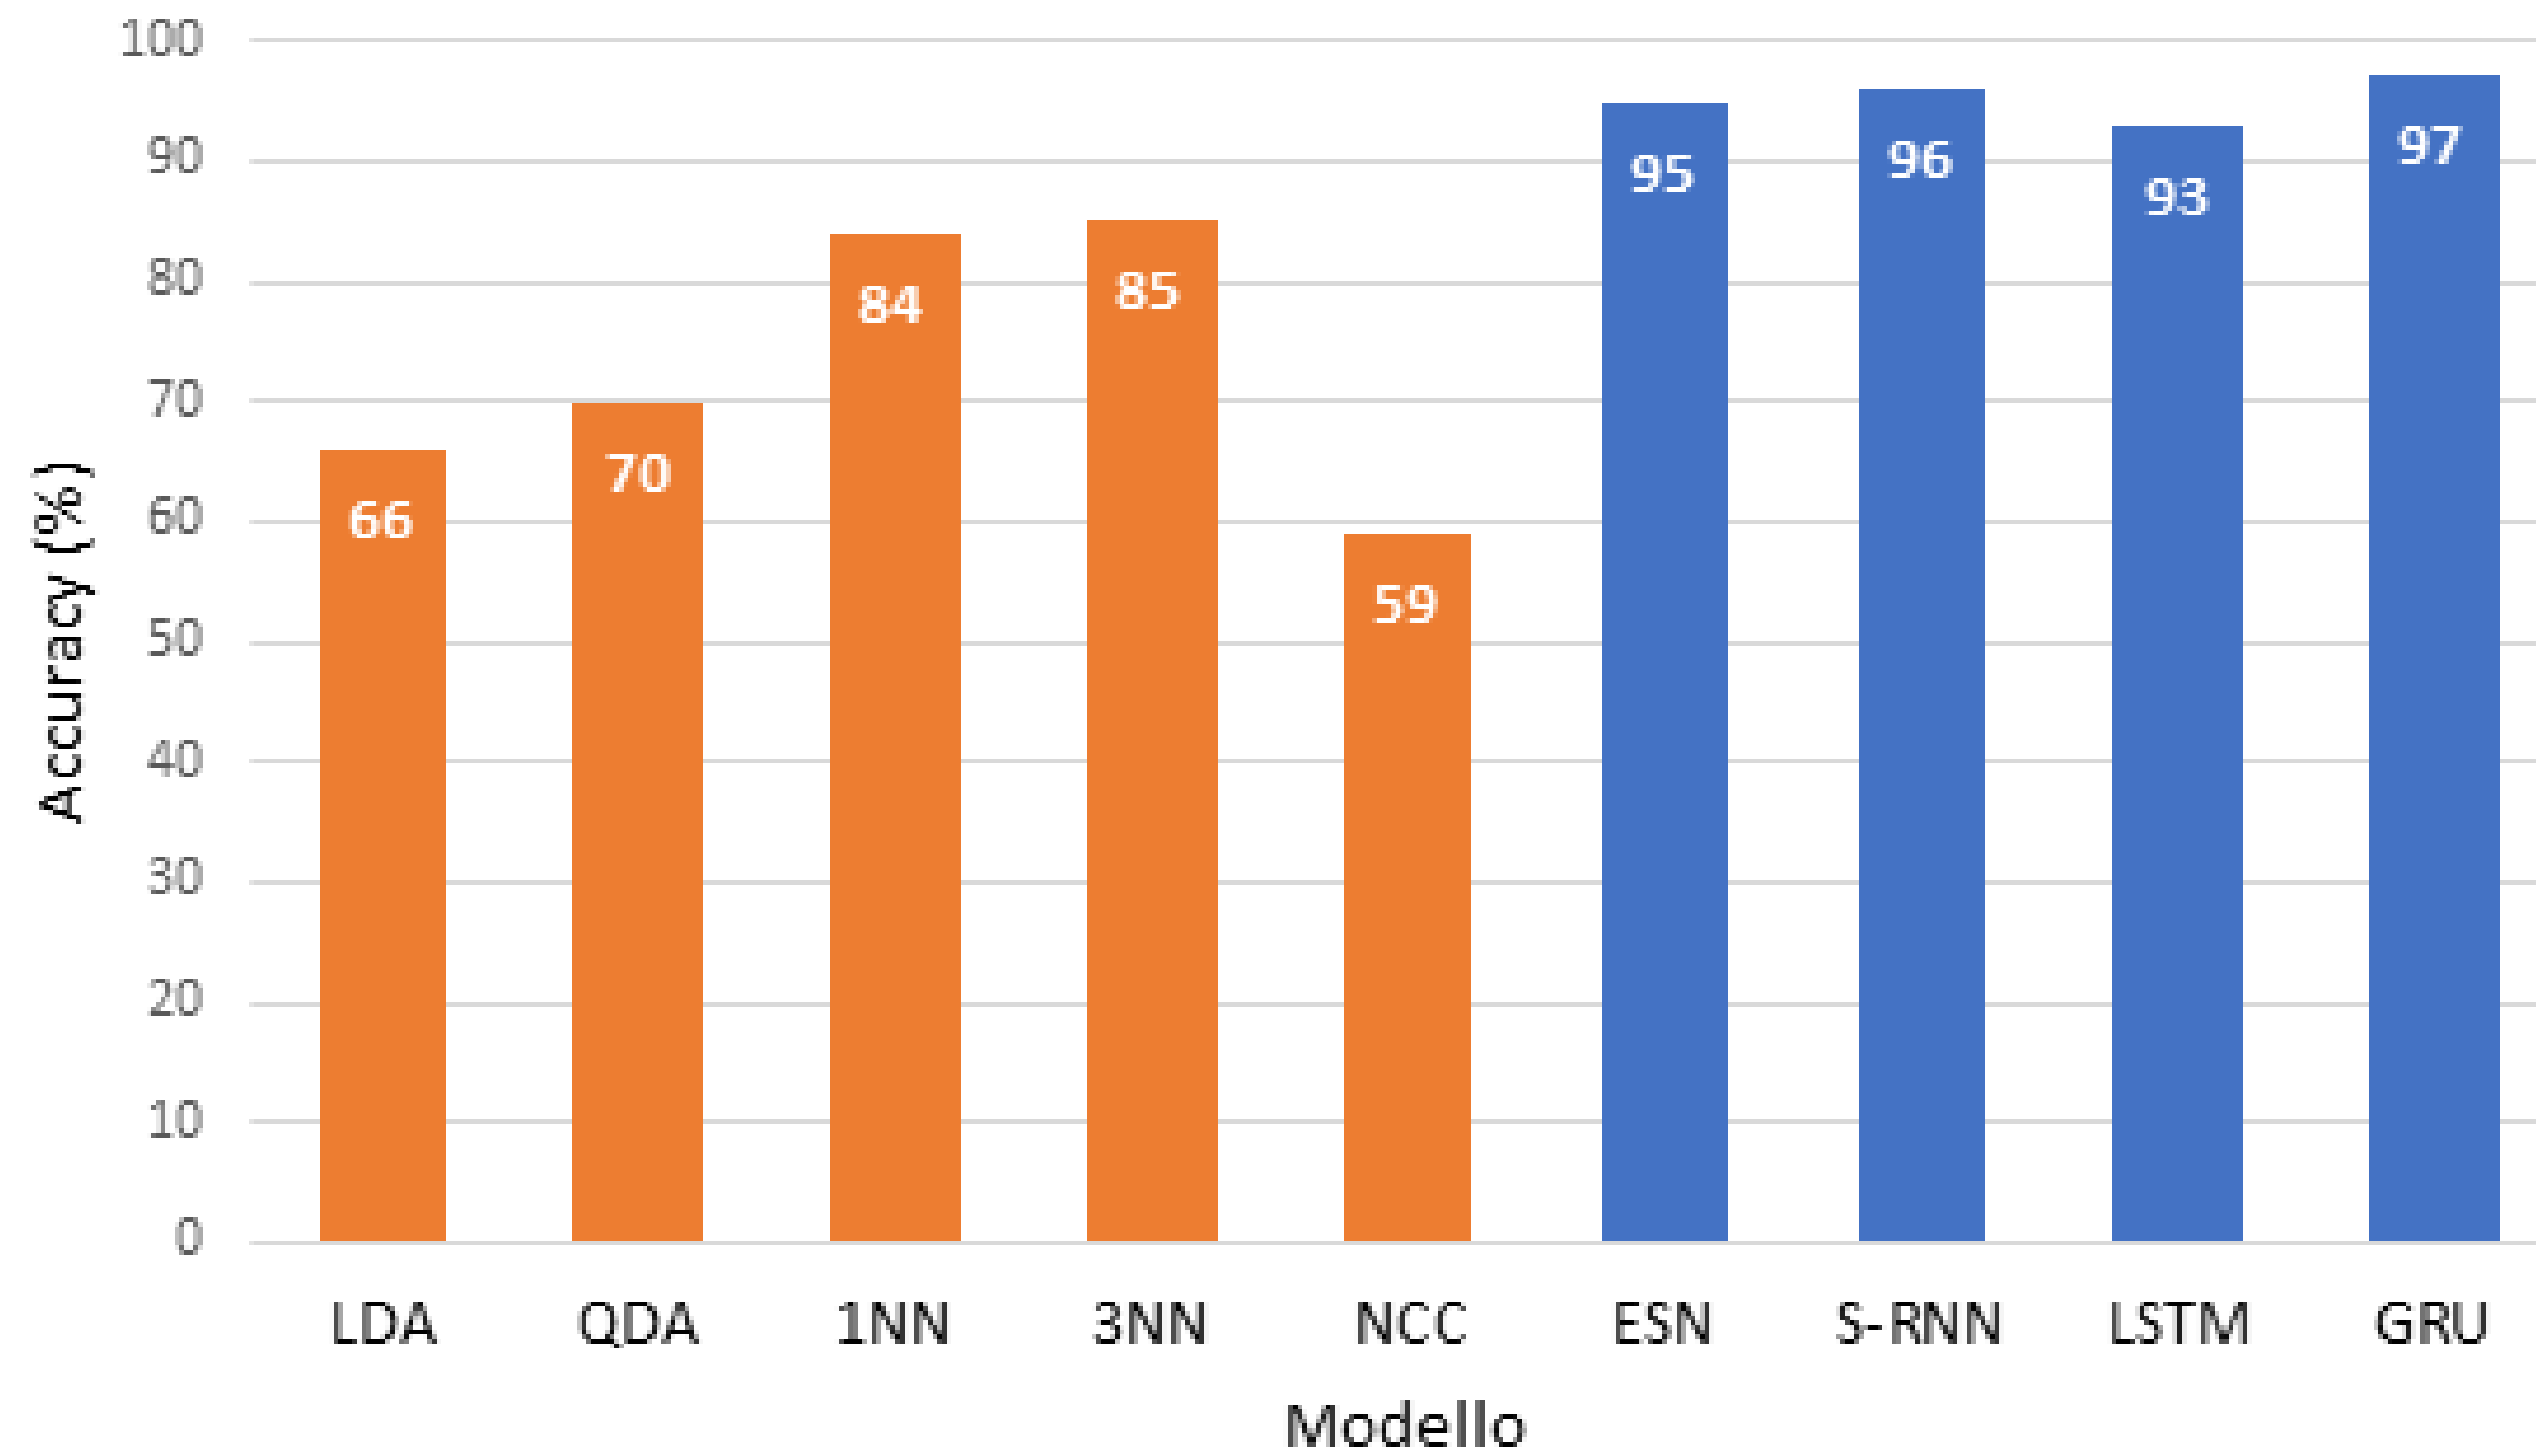
- **C4.5 DT** = C4.5 Decision Tree [4].
- **Boosted C4.5 DT** = Boosted C4.5 Decision Tree [4].
- **Bagging C4.5 DT** = Bagging C4.5 Decision Tree [4].
- **kNN** = k Nearest Neighbors [4].

*: Addestramento tramite 9-Folds-CV.

[4]: Attila Reiss and Didier Stricker, "Introducing a New Benchmarked Dataset for Activity Monitoring", in: The 16th IEEE International Symposium on Wearable Computers (ISWC), 2012.



OPPORTUNITY

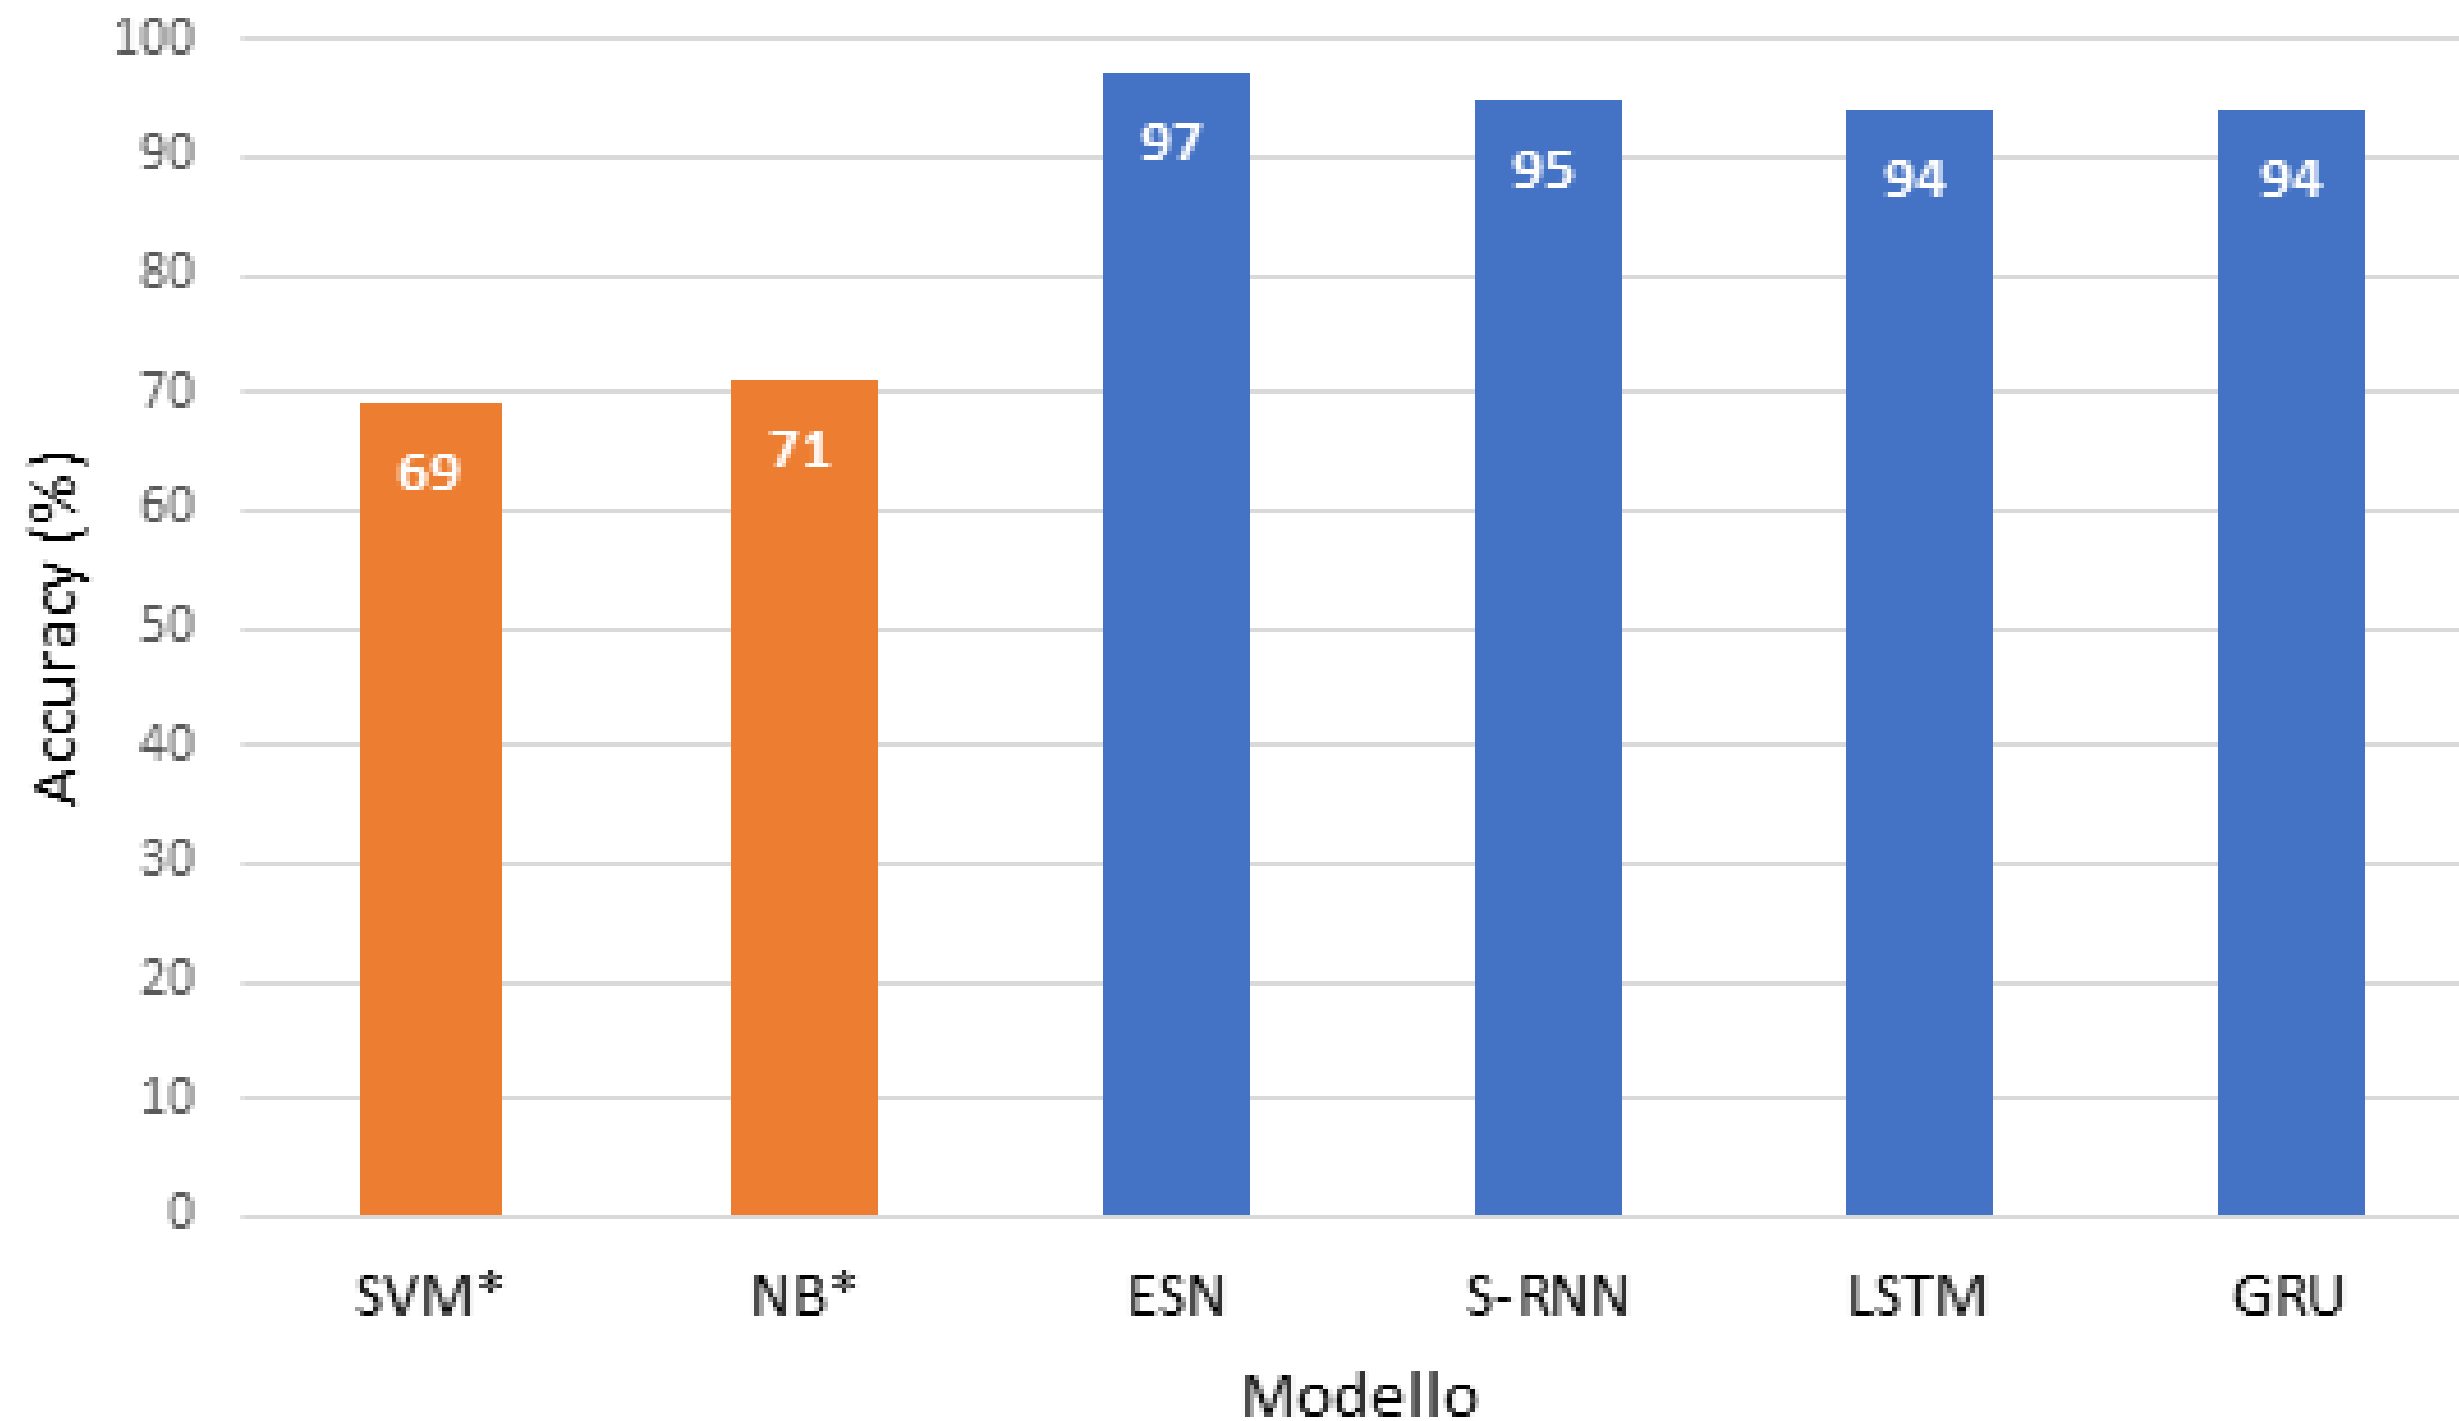


- **LDA** = Linear Discriminant Analysis [5].
- **QDA** = Quadratic Discriminant Analysis [5].
- **1NN** = 1 Nearest Neighbour [5].
- **3NN** = 3 Nearest Neighbors [5].
- **NCC** = Nearest Centroid Classifier [5].

[5]: Hesam Sagha et al., "Benchmarking classification techniques using the Opportunity human activity dataset", in: IEEE International Conference on Systems, Man, and Cybernetics, Anchorage, AK, USA, 2011.



ASCERTAIN



- **SVM** = Support Vector Machines [6].
- **NB** = Naive Bayes [6].

*: Addestramento tramite Leave-One-Subject-Out-CV.

Sommario dell'*accuracy*

	WESAD	HAR	PAMAP2	OPPORTUNITY	ASCERTAIN
State of the art	Ada-Boost DT	Deep Neural Newtork FF	k-Nearest Neighbors	k-Nearest Neighbors	Naive Bayes
⬆	GRU	GRU	GRU ESN	GRU	ESN
=	S-RNN LSTM ESN	LSTM ESN	S-RNN LSTM	S-RNN LSTM ESN	S-RNN LSTM GRU
⬇		S-RNN			



Conclusioni

- Nel complesso, *accuracy* delle RNN stabilmente **oltre il 90%**.
- **Compromesso** tra complessità e prestazioni.
- Prestazioni migliori raggiunte dal modello **GRU**.
- Risultati **ESN** concorrono con gli altri modelli di RNN più complessi (LSTM, GRU), pur addestrando esclusivamente il ***readout***.
 - *Echo State Networks* preferibili in contesti di applicazioni distribuite su **dispositivi *low-power***.

Progetto TEACHING

Benchmarking Reservoir and Recurrent Neural Networks for Human State and Activity Recognition*

Davide Bacciu^[0000-0001-5213-2468], Daniele Di Sarli^[0000-0003-4129-0131],
Claudio Gallicchio^[0000-0002-6692-2564], Alessio Micheli^[0000-0001-5764-5238],
and Niccolò Puccinelli

University of Pisa, Pisa, Italy

➤ **Inviato**



Grazie per l'attenzione

